Notebook de Análise Exploratória de Dados (AED)

In [1]:

```
import pandas as pd
from collections import Counter
%matplotlib inline
%pylab inline
import matplotlib.pyplot as plt
import seaborn as sns
plt.style.use('ggplot')
```

```
Populating the interactive namespace from numpy and matplotlib
```

In [2]:

```
dtypes = {  'Regiao': 'object',
            'UF': 'object',
            'CNAE': 'object',
            'Atendida':'bool',
            'CodAssunto': 'object',
            'SexoConsumidor': 'object',
            'FaixaEtaria': 'object',
            'CEP': 'object',
            'InscritoDAU':'bool'}
```

In [3]:

```
df_aed = pd.read_csv(r'C:\Users\73594253368\Desktop\Curso\Datasets\Procon\df_aed.csv',
```

In [4]:

```
df_aed.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10519 entries, 0 to 10518
Data columns (total 10 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Unnamed: 0      10519 non-null  int64
 1   Regiao          10519 non-null  object
 2   UF              10519 non-null  object
 3   CNAE            10519 non-null  object
 4   Atendida        10519 non-null  bool
 5   CodAssunto      10519 non-null  object
 6   SexoConsumidor  10519 non-null  object
 7   FaixaEtaria     10519 non-null  object
 8   CEP             10519 non-null  object
 9   InscritoDAU     10519 non-null  bool
dtypes: bool(2), int64(1), object(7)
memory usage: 678.1+ KB
```

In [5]:

```
# Retiraremos a coluna 'Unnamed: 0'
# Com isso, temos apenas variáveis categóricas
df_aed.drop(columns='Unnamed: 0',inplace=True)
```

Parte I - Análise Univariada

1) Variável da Coluna "Região"

In [6]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['Regiao']).unique().shape)
unique_regiao = df_aed['Regiao'].unique()
print(unique_regiao)
cont_regiao = df_aed['Regiao'].value_counts()
print(cont_regiao)

```

```
Valores únicos (5,)
['Norte' 'Nordeste' 'Sudeste' 'Sul' 'Centro-oeste']
Sudeste         5627
Centro-oeste    1977
Norte           1240
Nordeste        1153
Sul              522
Name: Regiao, dtype: int64
```

In [7]:

```
# Gráfico de Colunas

sns.barplot(cont_regiao.index, cont_regiao.values)
```

```
D:\ANACONDA\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass
the following variables as keyword args: x, y. From version 0.12, the only v
alid positional argument will be `data`, and passing other arguments without
an explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

Out[7]:

```
<AxesSubplot:>
```

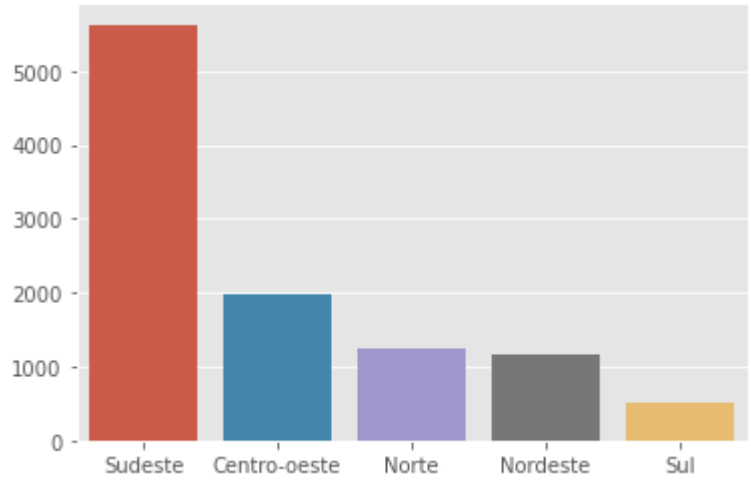

Verifica-se, portanto, maior número na Região Sudeste

2) Variável da Coluna "UF"

In [8]:

```
# Descrição dos valores da variável
# Informamos que a base original contém apenas 15 UF
print('Valores únicos',(df_aed['UF']).unique().shape)
unique_uf = df_aed['UF'].unique()
print(unique_uf)
cont_uf = df_aed['UF'].value_counts()
print(cont_uf)
```

```
Valores únicos (15,)
['RO' 'RN' 'MG' 'CE' 'ES' 'SP' 'RJ' 'PR' 'SC' 'MT' 'GO' 'PB' 'RS' 'MS'
 'PA']
SP    2865
GO    1337
RJ    1336
RO    1208
MG    1086
RN     994
MT     561
SC     452
ES     340
PB      90
MS      79
CE      69
PR      38
RS      32
PA      32
Name: UF, dtype: int64
```

In [9]:

```
# Gráfico de Colunas
cont_uf = cont_uf[:27] # Informamos que a base original contém apenas 15 UF, não aprese
sns.barplot(cont_uf.index, cont_uf.values)
```

```
D:\ANACONDA\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass
the following variables as keyword args: x, y. From version 0.12, the only v
alid positional argument will be `data`, and passing other arguments without
an explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

Out[9]:

```
<AxesSubplot:>
```

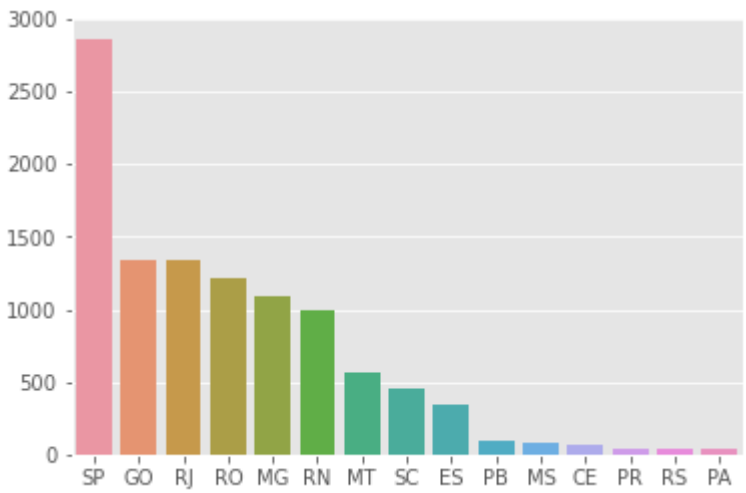

Em linha com o resultado da coluna "Região", São Paulo é a UF com mais demandas

In [10]:

```
# Gráfico de Barras para outra visualização
df_aed['UF'].value_counts().plot.barh()
```

Out[10]:

```
<AxesSubplot:>
```

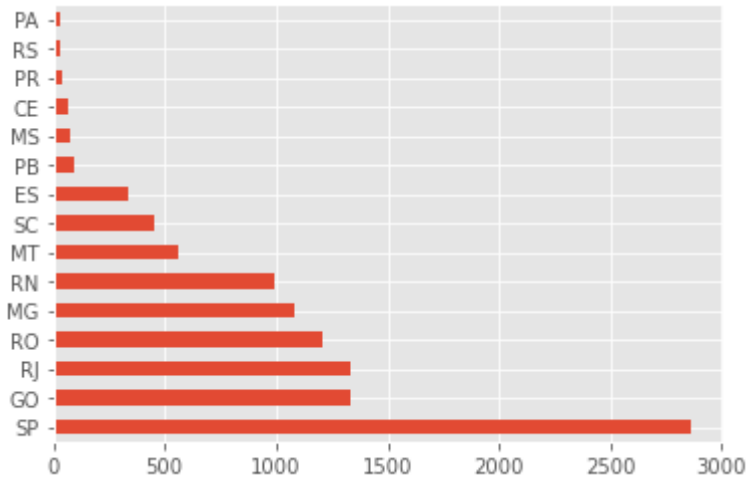

3) Variável da Coluna "CNAE"

Uma variável explicativa de cardinalidade muito elevada

In [11]:

```
# 2 CNAE - uma variável explicativa de cardinalidade muito elevada
print('Valores únicos',(df_aed['CNAE']).unique().shape)
unique_cnae = df_aed['CNAE'].unique()
# print(unique_cnae) #optamos por não printar
cont_cnae = df_aed['CNAE'].value_counts()
print(cont_cnae)
```

```
Valores únicos (368,)
6422100.0    992
3514000.0    664
6120501.0    663
6110801.0    572
4753900.0    529
            ...
5320202.0      1
4543900.0      1
9529105.0      1
1721400.0      1
6410700.0      1
Name: CNAE, Length: 368, dtype: int64
```

As partes mais altas do histograma correspondem aos que tiveram maiores ocorrências:

- 6422100 BANCO MÚLTIPLO COM CARTEIRA COMERCIAL - 992
- 3514000 ENERGIA ELÉTRICA; OPERAÇÃO DE SISTEMAS DE DISTRIBUIÇÃO DE0 - 664
- 6120501 SERVIÇO MÓVEL DE CELULAR - 663

- 6110801 COMUNICAÇÃO TELEFÔNICA CONVENCIONAL - 572
- 4753900 ELETRODOMÉSTICOS; COMÉRCIO VAREJISTA - 529

In [12]:

```
# Gráfico de Colunas do CNAE
# cont_cnae = cont_cnae[:10]  #Não executou quando colocamos as dez primeiras, p exempl

plt.figure(figsize= [20,8])
sns.barplot(cont_cnae.index, cont_cnae.values)

```

```
D:\ANACONDA\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass
the following variables as keyword args: x, y. From version 0.12, the only v
alid positional argument will be `data`, and passing other arguments without
an explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

Out[12]:

```
<AxesSubplot:>
```

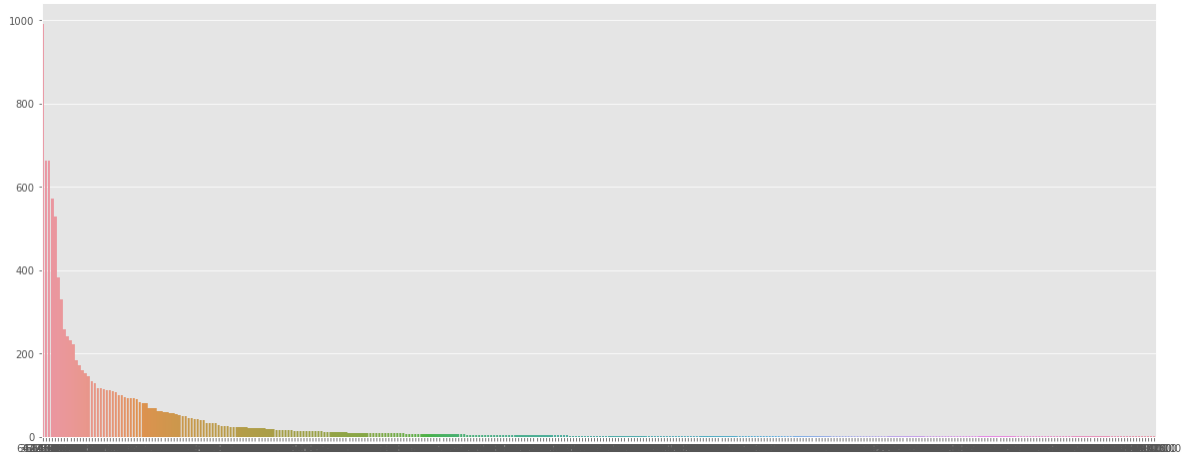

In [13]:

```
# Como vimos acima, a variável de elevada cardinalidade teve problemas. Colocaremos em
# aos dez maiores para melhorar a visualização
```

In [14]:

```
pc_cnae = (df_aed['CNAE'].value_counts(normalize = True) * 100).to_frame('Porcentagem')
pc_cnae.rename(columns = {'index': 'CNAE'}, inplace = True)
pc_cnae
```

Out[14]:

	CNAE	Porcentagem
0	6422100.0	9.430554
1	3514000.0	6.312387
2	6120501.0	6.302881
3	6110801.0	5.437779
4	4753900.0	5.028995
...	...	...
363	5320202.0	0.009507
364	4543900.0	0.009507
365	9529105.0	0.009507
366	1721400.0	0.009507
367	6410700.0	0.009507

368 rows × 2 columns

In [15]:

```
#Apenas os dez maiores valores
pc_cnae_dez = pc_cnae[:10]
```

In [16]:

```
#Gráfico de colunas com apenas os dez maiores
plt.figure(figsize= [20,8])
sns.barplot(x='CNAE',y='Porcentagem',data=pc_cnae_dez)
```

Out[16]:

```
<AxesSubplot:xlabel='CNAE', ylabel='Porcentagem'>
```

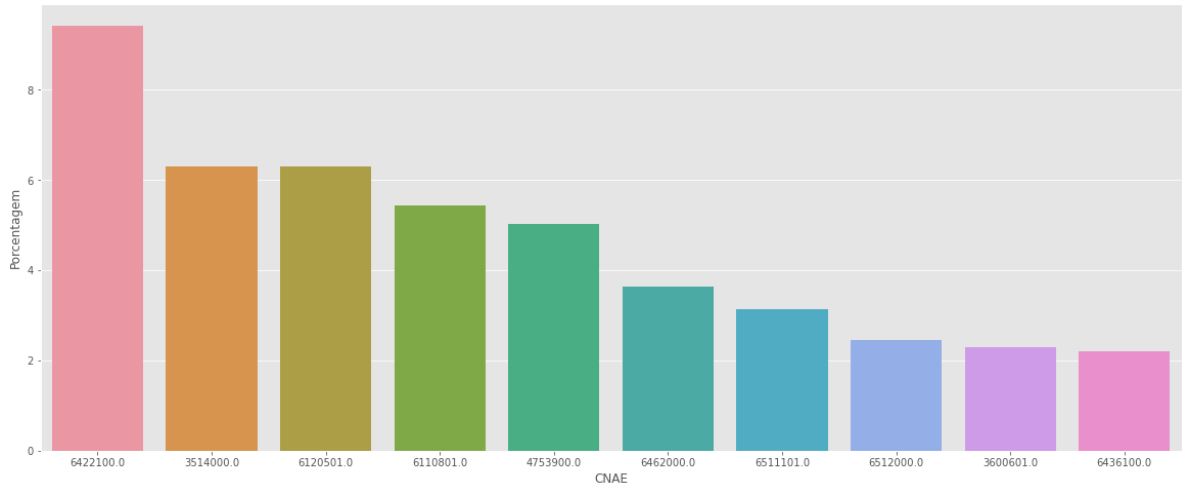

- 6422100 BANCO MÚLTIPLO COM CARTEIRA COMERCIAL - 9.43%
- 3514000 ENERGIA ELÉTRICA; OPERAÇÃO DE SISTEMAS DE DISTRIBUIÇÃO - 6.31%
- 6120501 SERVIÇO MÓVEL DE CELULAR - 6.30%
- 6110801 COMUNICAÇÃO TELEFÔNICA CONVENCIONAL - 5.43%
- 4753900 ELETRODOMÉSTICOS; COMÉRCIO VAREJISTA - 5.02%
- 6462000 EMPRESA NÃO-FINANCEIRA CONTROLADORA - 3.64%
- 6511101 SEGURO DE VIDA - 3.13%
- 6512000 ADMINISTRADORA DE SEGUROS NÃO VIDA - 2.45%
- 3600601 ABASTECIMENTO DE ÁGUA; SERVIÇO DE - 2.30%
- 6436100 COMPANHIA DE CRÉDITO, FINANCIAMENTO E INVESTIMENTO (FINANCEIRA) 2.19%

4) Variável da Coluna "Atendida" (booleana)

In [17]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['Atendida']).unique().shape)
unique_Atendida = df_aed['Atendida'].unique()
print(unique_Atendida)
cont_Atendida = df_aed['Atendida'].value_counts()
print(cont_Atendida)
```

```
Valores únicos (2,)
[False  True]
True     6306
False    4213
Name: Atendida, dtype: int64
```

In [18]:

```
#Countplot
plt.figure(figsize= [4,6])
sns.countplot(x='Atendida', data=df_aed)
```

Out[18]:

```
<AxesSubplot:xlabel='Atendida', ylabel='count'>
```

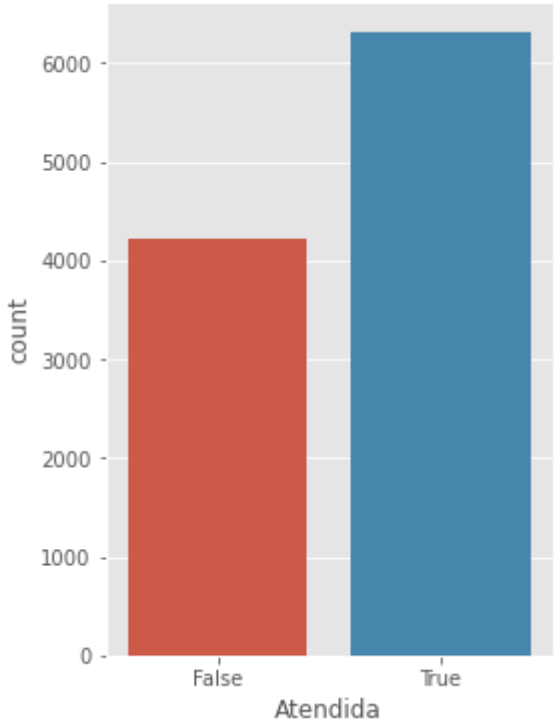

Nossa variável "target" está desbalanceada. Ajustaremos isso no notebook de Machine Learning, com aplicação de SMOTE.

5) Variável da Coluna "CodAssunto"

Uma variável explicativa de cardinalidade muito elevada

In [19]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['CodAssunto']).unique().shape)
# unique_ca = df_aed['CodAssunto'].unique()
# print(unique_ca) #optamos por não printar
cont_ca = df_aed['CodAssunto'].value_counts()
plt.figure(figsize= [20,8])
sns.barplot(cont_ca.index, cont_ca.values)
```

```
Valores únicos (175,)

D:\ANACONDA\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass
the following variables as keyword args: x, y. From version 0.12, the only v
alid positional argument will be `data`, and passing other arguments without
an explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

Out[19]:

```
<AxesSubplot:>
```

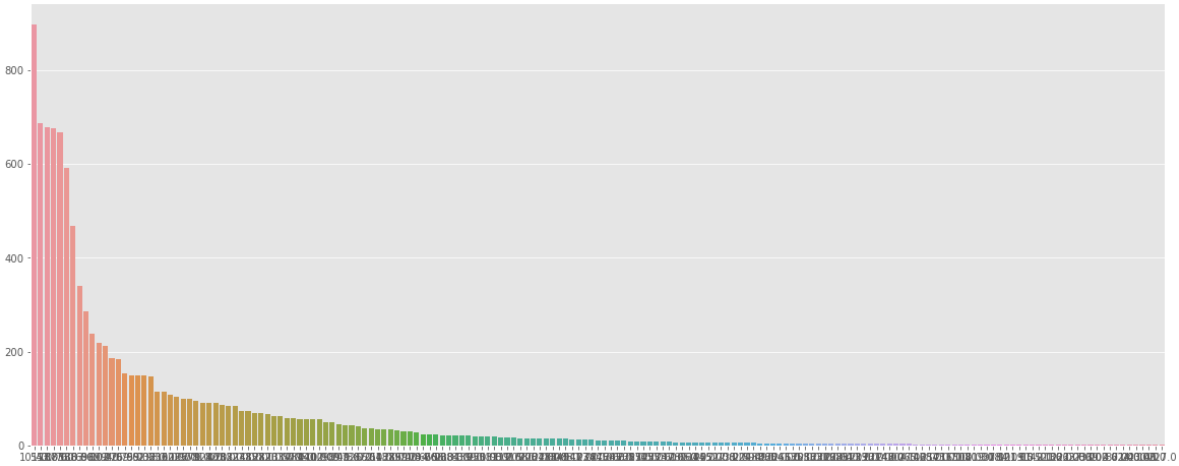

In [20]:

```
# Da mesma forma que a Coluna "CNAE", essa variável de elevada cardinalidade teve probl
# Colocaremos em percentual e restringiremos aos dez maiores para melhorar a visualizaç
```

In [21]:

```
# Nas variáveis categóricas de alta cardinalidade, colocaremos em percentual e restring
pc_ca = (df_aed['CodAssunto'].value_counts(normalize = True) * 100).to_frame('Porcentag
pc_ca.rename(columns = {'index': 'CodAssunto'}, inplace = True)
pc_ca
pc_ca_dez = pc_ca[:10]
```

In [22]:

```
1 pc_ca_dez
```

Out[22]:

	CodAssunto	Porcentagem
0	101.0	8.536933
1	54.0	6.521532
2	53.0	6.454986
3	187.0	6.416960
4	185.0	6.350414
5	76.0	5.618405
6	186.0	4.449092
7	183.0	3.222740
8	63.0	2.709383
9	96.0	2.262572

In [23]:

```
1 # Gráfico com as dez maiores ocorrências de CodAssunto
2 plt.figure(figsize= [20,8])
3 sns.barplot(x='CodAssunto',y='Porcentagem',data=pc_ca_dez)
```

Out[23]:

```
<AxesSubplot:xlabel='CodAssunto', ylabel='Porcentagem'>
```

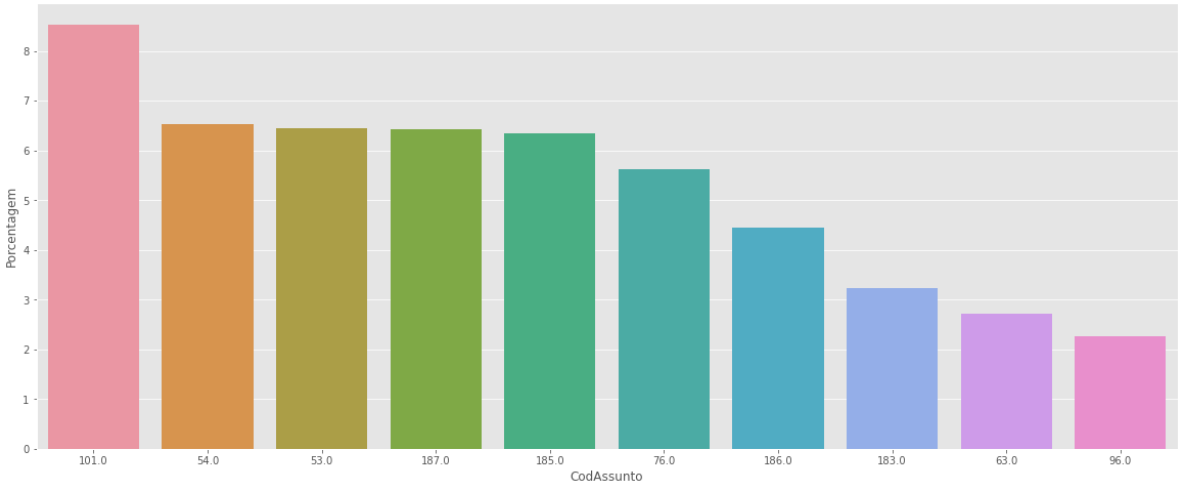

Maiores ocorrências:

- 101 - Telefone (Convencional) - 8.53%
- 54 - Cartão de Crédito - 6.52%
- 53 - Banco comercial - 6.45%
- 187 - Telefonia Celular - 6.41%
- 185 - Energia Elétrica - 6.35%
- 76 - "Outros Contratos" - 5.61%

- 186 - Telefonia Fixa (Plano de Expansão / Compra e Venda / Locação) - 4.44%
- 183 - Água / Esgoto - 3.22%
- 63 - Financeira 2.70%
- 96 - Televisão 2.26%

6) Variável da Coluna "SexoConsumidor"

In [24]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['SexoConsumidor']).unique().shape)
unique_sexo = df_aed['SexoConsumidor'].unique()
print(unique_sexo)
cont_sexo = df_aed['SexoConsumidor'].value_counts()
print(cont_sexo)
```

```
Valores únicos (2,)
['M' 'F']
F    5529
M    4990
Name: SexoConsumidor, dtype: int64
```

In [25]:

```
#Gráfico de Colunas SexoConsumidor
plt.figure(figsize= [4,6])
sns.barplot(cont_sexo.index, cont_sexo.values,palette=['r','b'])

```

```
D:\ANACONDA\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass
the following variables as keyword args: x, y. From version 0.12, the only v
alid positional argument will be `data`, and passing other arguments without
an explicit keyword will result in an error or misinterpretation.
  warnings.warn(
```

Out[25]:

```
<AxesSubplot:>
```

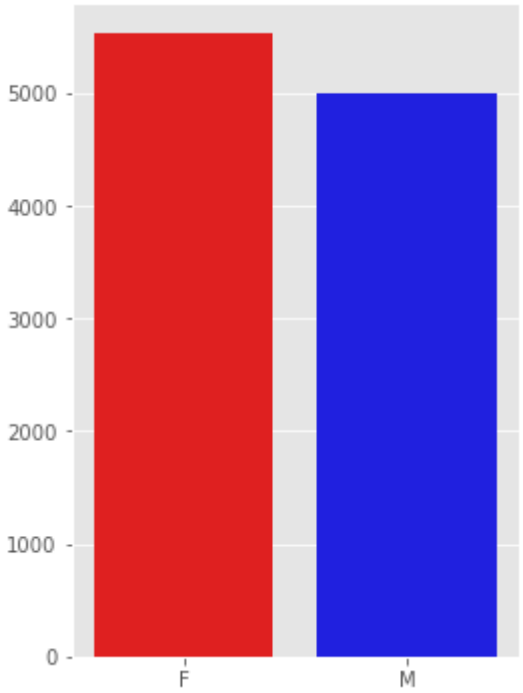

Um ligeiro número maior de reclamações do sexo feminino: 5529, ante 4990.

7) Variável da Coluna "FaixaEtaria"

Informamos que a variável já veio discretizada na base original, em https://dados.gov.br/dataset/cadastro-nacional-de-reclamacoes-fundamentadas-procons-sindec1 (https://dados.gov.br/dataset/cadastro-nacional-de-reclamacoes-fundamentadas-procons-sindec1). Sendo assim, é uma variável categórica.

In [26]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['FaixaEtaria']).unique().shape)
unique_fa = df_aed['FaixaEtaria'].unique()
print(unique_fa)
cont_fa = df_aed['FaixaEtaria'].value_counts()
print(cont_fa)
```

```
Valores únicos (7,)
['5' '4' '3' '6' '7' '2' '1']
3    2461
4    2105
5    1816
6    1617
2    1601
7     723
1     196
Name: FaixaEtaria, dtype: int64
```

In [27]:

```
# Gráfico de Colunas

sns.countplot(x='FaixaEtaria',data=df_aed)
```

Out[27]:

```
<AxesSubplot:xlabel='FaixaEtaria', ylabel='count'>
```

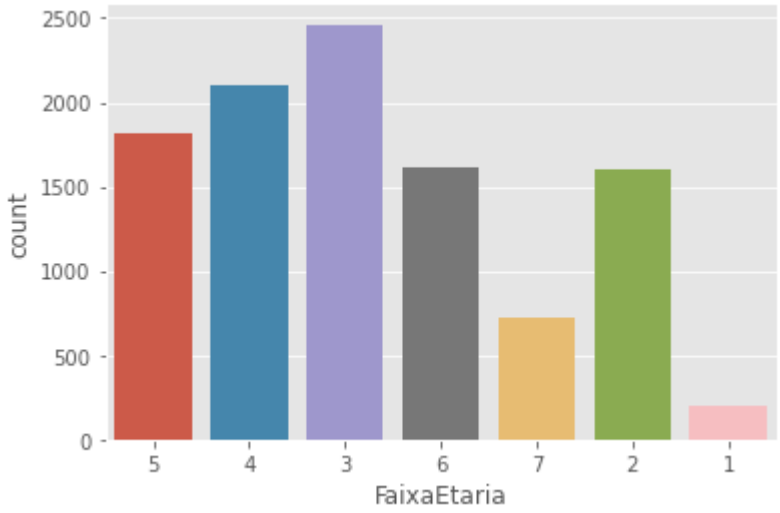

- Faixa 1: até 20 anos
- Faixa 2: entre 21 a 30 anos
- Faixa 3: entre 31 a 40 anos
- Faixa 4: entre 41 a 50 anos
- Faixa 5: entre 51 a 60 anos
- Faixa 6: entre 61 a 70 anos
- Faixa 7: mais de 70 anos

In [28]:

```
# Problemas de exibição, acima. Converteremos para inteiros para possibilitar a ordem
df_aed = df_aed.astype({'FaixaEtaria': int})
sns.countplot(x='FaixaEtaria',data=df_aed)
```

Out[28]:

```
<AxesSubplot:xlabel='FaixaEtaria', ylabel='count'>
```

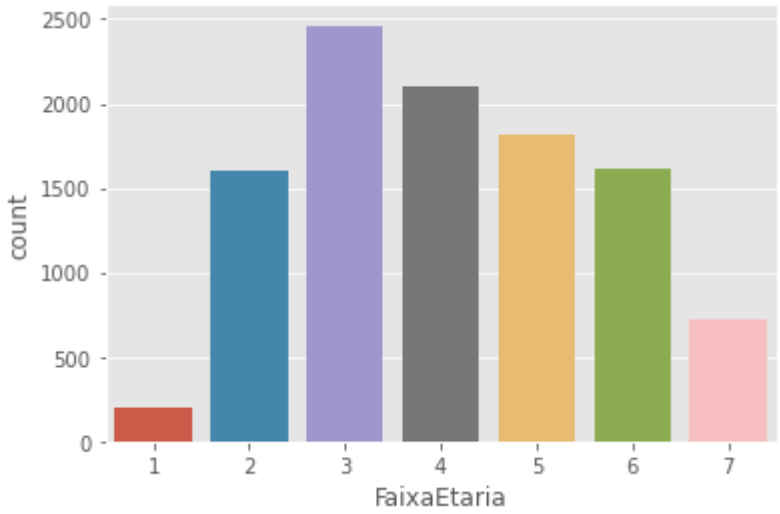

Nenhuma surpresa. Parece que o maior número de demandas ocorre nas faixas 3 (entre 31 a 40 anos) e 4 (entre 41 a 50).

In [29]:

```
# Resolvido o problema de exibição, retornaremos ao object
df_aed = df_aed.astype({'FaixaEtaria': object})
```

8) Variável da Coluna "CEP"

Elevadíssima cardinalidade. São 6354 valores diferentes. Mantivemos esta coluna apenas para representar a realidade. O CEP é um fator que pode influenciar na variável-target "Atendida"

In [30]:

```
 #8   CEP
print('Valores únicos',(df_aed['CEP']).unique().shape)
# unique_CEP  = df_aed['CEP'].unique()
# print(unique_CEP) - optamos por não printar os 6354 valores
cont_CEP = df_aed['CEP'].value_counts()
print(cont_CEP)
```

```
Valores únicos (6354,)
75860000.0    351
78700000.0    173
27901000.0     84
75690000.0     75
79240000.0     68
             ...
76808260.0      1
29220210.0      1
23560417.0      1
59140160.0      1
59125090.0      1
Name: CEP, Length: 6354, dtype: int64
```

CEPs com mais números. Não estranhamente em cidades que tem apenas o CEP final "000". A maior delas, Macaé-RJ, tem menos de 300.000 habitantes

- 75860000 351 Quirinópolis - GO
- 78700000 173 Rondonopolis - MT
- 27901000 84 Macaé - RJ
- 75690000 75 Caldas Novas - GO
- 79240000 68 Jardim - MS

In [31]:

```
# Devido às 6354 linhas a representar, os gráficos não retornavam informação alguma. Te
# Gráfico de Colunas da base inteira #Leva muito tempo e gera pouca informação
```

In [32]:

```
# Nas variáveis categóricas de alta cardinalidade, colocaremos em percentual e restring
pc_cep = (df_aed['CEP'].value_counts(normalize = True) * 100).to_frame('Porcentagem').r
pc_cep.rename(columns = {'index': 'CEP'}, inplace = True)
pc_cep
pc_cep_dez = pc_cep[:10]
```

In [33]:

```
1 pc_cep_dez
```

Out[33]:

	CEP	Porcentagem
0	75860000.0	3.336819
1	78700000.0	1.644643
2	27901000.0	0.798555
3	75690000.0	0.712996
4	79240000.0	0.646449
5	14850000.0	0.636943
6	35600000.0	0.627436
7	78850000.0	0.627436
8	36500000.0	0.598916
9	88385000.0	0.598916

In [34]:

```
1 # Gráfico de colunas mostrando os CEPs com mais demandas
2 plt.figure(figsize= [12,8])
3 result = pc_cep_dez.groupby(['CEP'])['Porcentagem'].aggregate(np.sum).reset_index().sor
4 sns.barplot(x='CEP',y='Porcentagem',data=pc_cep_dez,order=result['CEP']) # para ordenar
```

Out[34]:

```
<AxesSubplot:xlabel='CEP', ylabel='Porcentagem'>
```

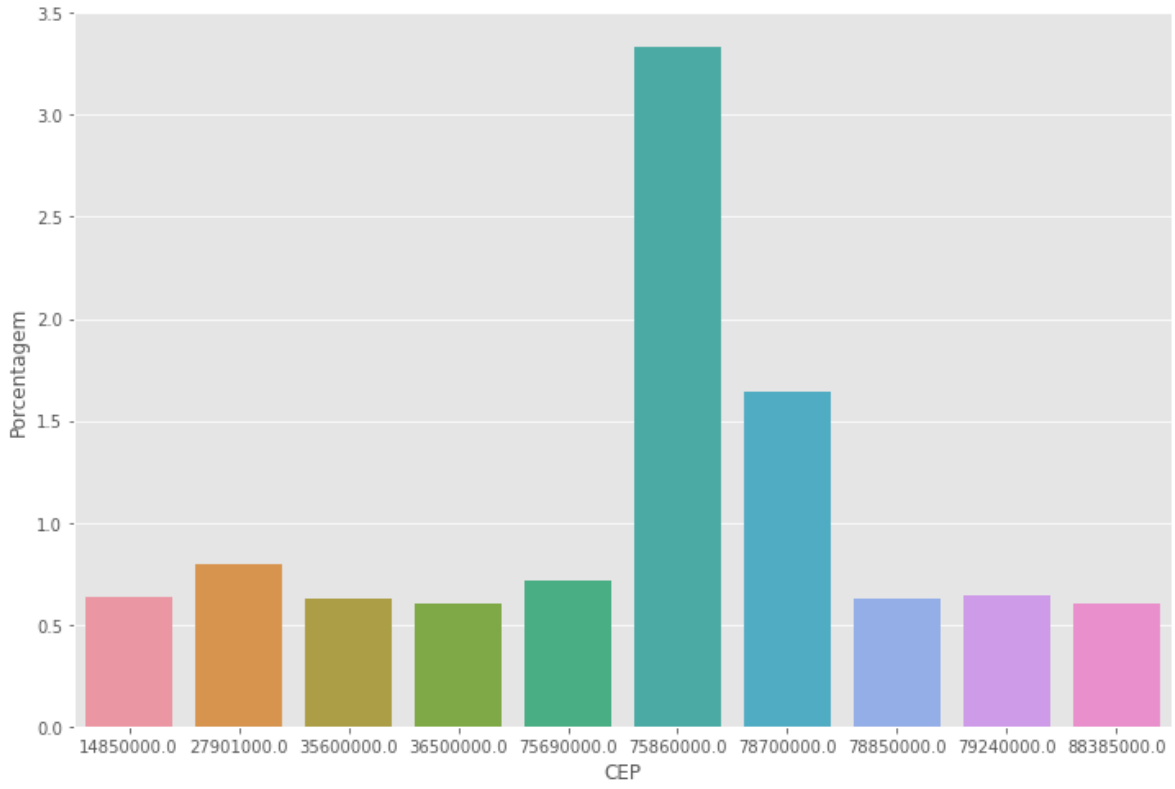

- 75860000 - Quirinópolis - GO - 3.33%
- 78700000 - Rondonopolis - MT - 1.64%
- 27901000 - Macaé - RJ - 0.79%
- 75690000 - Caldas Novas - GO - 0.71%
- 79240000 - Jardim - MS - 0.64%
- 14850000 - Pradópolis - SP - 0.63%
- 78850000 - Primavera do Leste - MT - 0.62%
- 35600000 - Bom Despacho - MG - 0.62%
- 36500000 - Ubá - MG - 0.59%
- 88385000 - Penha - SC - 0.59%

9) Variável da Coluna "InscritoDAU" (booleana)

In [35]:

```
# Descrição dos valores da variável
print('Valores únicos',(df_aed['InscritoDAU']).unique().shape)
unique_InscritoDAU = df_aed['InscritoDAU'].unique()
print(unique_InscritoDAU)
cont_InscritoDAU = df_aed['InscritoDAU'].value_counts()
print(cont_InscritoDAU)
```

```
Valores únicos (2,)
[ True False]
True     6365
False    4154
Name: InscritoDAU, dtype: int64
```

In [36]:

```
#Countplot
sns.countplot(x='InscritoDAU', data=df_aed)
```

Out[36]:

```
<AxesSubplot:xlabel='InscritoDAU', ylabel='count'>
```

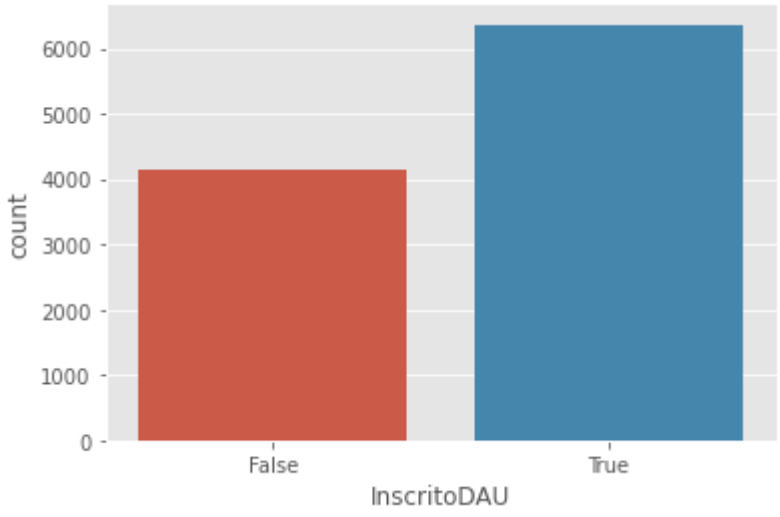

Preparação para utilizar a biblioteca de visualização Bokeh em gráficos de # análise bivariada

In [37]:

```
# Importação da biblioteca para geração dos gráficos
from bokeh.layouts import row
from bokeh.io import output_notebook, show
from bokeh.layouts import row, column
from bokeh.models import ColumnDataSource, FactorRange, LabelSet, Range1d, Legend, Line
from bokeh.plotting import figure
from bokeh.palettes import Spectral6, Category20
output_notebook()
import pandas_bokeh
```

In [38]:

```
# Definição de parâmetros de Função que recebe um df e uma coluna categórica e retorna

def grafico_relacao_atributo_target(df_aed, col, width=650, height=400, y_offset_qtde =
    totais = [("qtd_total", "count"),
              ("qtd_atendida_True", lambda x: (x == True).sum()),
              ("qtd_atendida_False", lambda x: (x == False).sum())]
    dfy = df_aed.groupby(col).agg({"Atendida": totais}).reset_index()
    dfy.columns = [col, "qtd_total", "qtd_atendida_True", "qtd_atendida_False"]
    dfy["perc_atendida_True"] = round((dfy["qtd_atendida_True"] / dfy["qtd_total"]) * 1
    dfy["perc_atendida_False"] = round((dfy["qtd_atendida_False"] / dfy["qtd_total"]) *
    if str(dfy[col].dtype) in ['bool','int64', 'float64']:
        dfy[col] = dfy[col].astype('str')
    maxValue = dfy["qtd_total"].max()
    if len(dfy) > 15:
        dfy = dfy.sort_values("qtd_total", ascending=False).head(True2)
        title = col + "(12 maiores classes)"
    else:
        title = col
    cds = ColumnDataSource(dfy)
    p = figure(x_range=dfy[col].tolist(), plot_height=height, plot_width=width, title =
    Legend()
    p.add_layout(Legend(label_text_font_size='7pt'), 'right')
    p.vbar(x=col, top = "qtd_total", source=cds, width = 0.7)
    p.extra_y_ranges["perc"] = Range1d(start=0, end=109)
    p.yaxis.axis_label = "Quantidade de registros"
    p.y_range.end = int(maxValue * 1.07)
    p.add_layout(LinearAxis(y_range_name="perc", axis_label = "[%] em relação ao total
                            axis_label_text_font_size = "8pt", ticker=SingleIntervalTic
    p.yaxis.formatter.use_scientific = False
    if mlo != None:
        p.xaxis.major_label_orientation = mlo
        p.xaxis.major_label_text_font_size = '7pt'
    p.line(x = col, y = "perc_atendida_True", source=cds, legend_label = "% Atendida =
    p.circle(x = col, y = "perc_atendida_True", size=8, source=cds, legend_label = "% A
    p.line(x = col, y = "perc_atendida_False", source=cds, legend_label = "% Atendida =
    p.circle(x = col, y = "perc_atendida_False", size=8, source=cds, legend_label = "%
    labelsQtde = LabelSet(x = col, y = "qtd_total", text = "qtd_total", level = "glyph"
                          source = cds, render_mode="canvas", text_align="center", text_
    labelsPercAtendTrue = LabelSet(x = col, y = "perc_atendida_True", y_range_name = "p
                          source = cds,  render_mode="css", text_align="center", text_co
    labelsPercAtendFalse = LabelSet(x = col, y = "perc_atendida_False", y_range_name =
                          source = cds,  render_mode="css", text_align="center", text_co
    p.title.text_font_size = 'TrueFalsept'
    p.title.align='center'
    p.add_layout(labelsQtde)
    p.add_layout(labelsPercAtendTrue)
    p.add_layout(labelsPercAtendFalse)
    return p

```

Parte II - Análise Bivariada, comparando cada uma das variáveis com a variável target.

1) Coluna "Região" X target "Atendida"

In [39]:

```
# Quantidade em que a Atendida é "True"
df_aed.groupby('Regiao').agg({'Atendida': ['sum']})
```

Out[39]:

	Atendida
	sum
Regiao	
Centro-oeste	1447
Nordeste	661
Norte	640
Sudeste	3213
Sul	345

In [40]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'Regiao','Atendida'
df_reg = df_aed.groupby(x)[y].value_counts(normalize = True)
df_reg = df_reg.mul(100)
df1 = df_reg.rename('Porcentagem').reset_index()
df1_filtrado =  df1[df1['Atendida']==True]
df1_filtrado
```

Out[40]:

	Regiao	Atendida	Porcentagem
0	Centro-oeste	True	73.191705
2	Nordeste	True	57.328708
4	Norte	True	51.612903
6	Sudeste	True	57.099698
8	Sul	True	66.091954

In [41]:

```
# Gráfico de colunas mostrando o maior número, em valores relativos, da Região Centro-O
plt.subplots(figsize=(5,5))
sns.barplot(x= 'Regiao', y= 'Porcentagem',data=df1_filtrado)
plt.show()
```

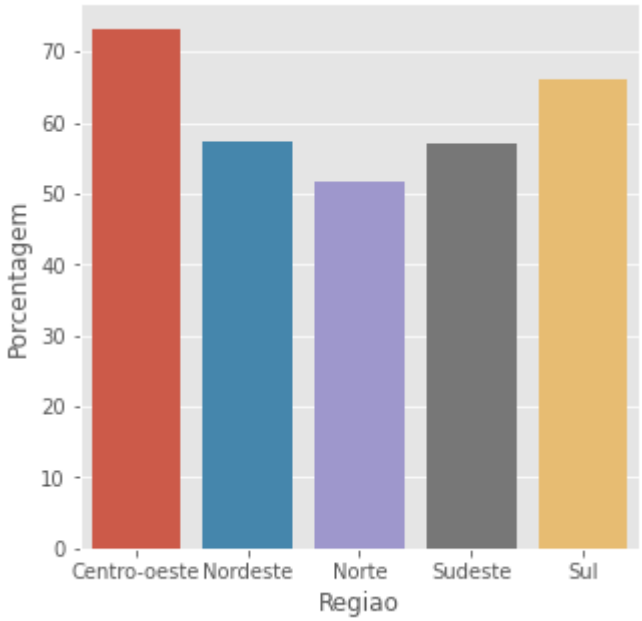

In [42]:

```
# Gráfico Bokeh para análise bivariada, monstrado valores absolutos (colunas) e relativ
g_reg  = grafico_relacao_atributo_target(df_aed, "Regiao")
show(g_reg)
```

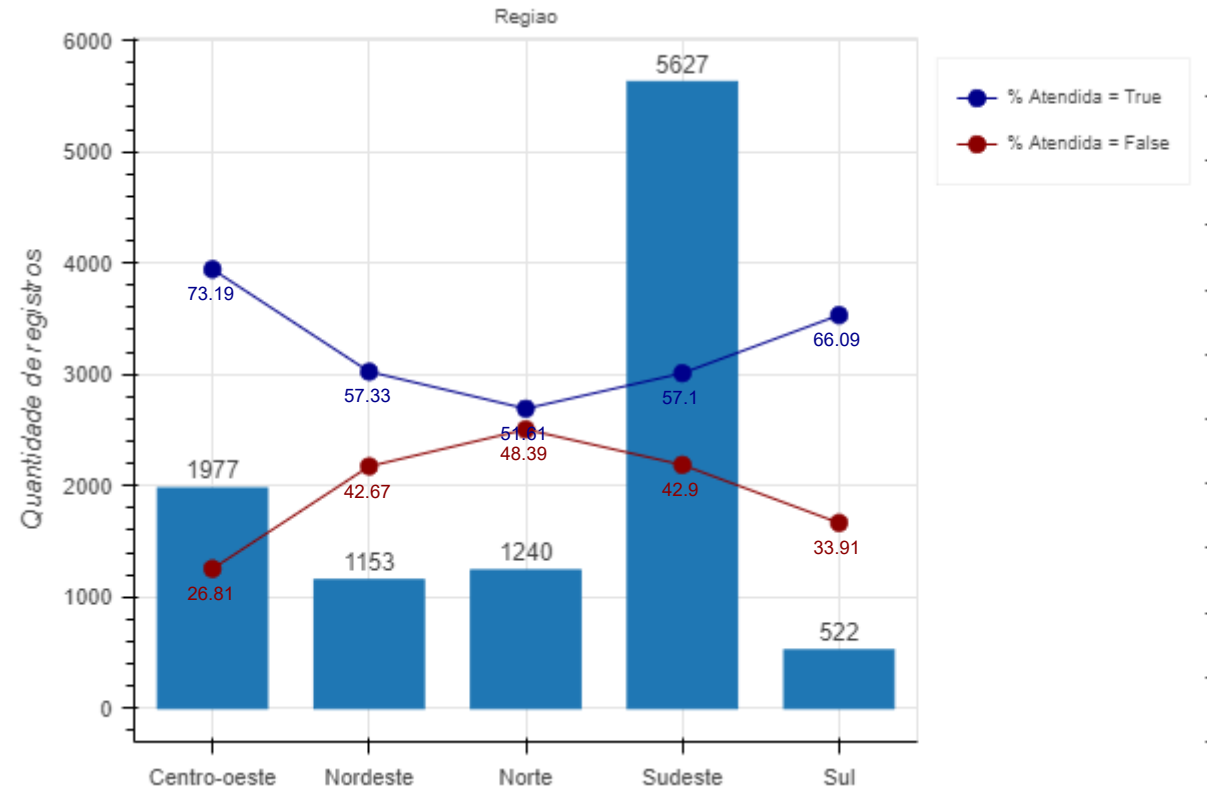

2) Coluna "UF" X target "Atendida"

In [43]:

```
# Quantidade em que a Atendida é "True"
df_aed.groupby('UF').agg({'Atendida': ['sum']})
```

Out[43]:

	Atendida
	sum
UF	
CE	40
ES	210
GO	954
MG	927
MS	4
MT	489
PA	16
PB	76
PR	22
RJ	890
RN	545
RO	624
RS	6
SC	317
SP	1186

In [44]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'UF','Atendida'
df_uf = df_aed.groupby(x)[y].value_counts(normalize = True)
df_uf = df_uf.mul(100)
df2 = df_uf.rename('Porcentagem').reset_index()
df2_filtrado =  df2[df2['Atendida']==True]
df2_filtrado
```

Out[44]:

	UF	Atendida	Porcentagem
0	CE	True	57.971014
2	ES	True	61.764706
4	GO	True	71.353777
6	MG	True	85.359116
9	MS	True	5.063291
10	MT	True	87.165775
13	PA	True	50.000000
14	PB	True	84.444444
16	PR	True	57.894737
18	RJ	True	66.616766
20	RN	True	54.828974
22	RO	True	51.655629
25	RS	True	18.750000
26	SC	True	70.132743
29	SP	True	41.396161

In [45]:

```
# Gráfico de colunas mostrando os valores relativos
plt.subplots(figsize=(10,8))
sns.barplot(x= df2_filtrado['UF'], y= df2_filtrado['Porcentagem'])
plt.show()
```

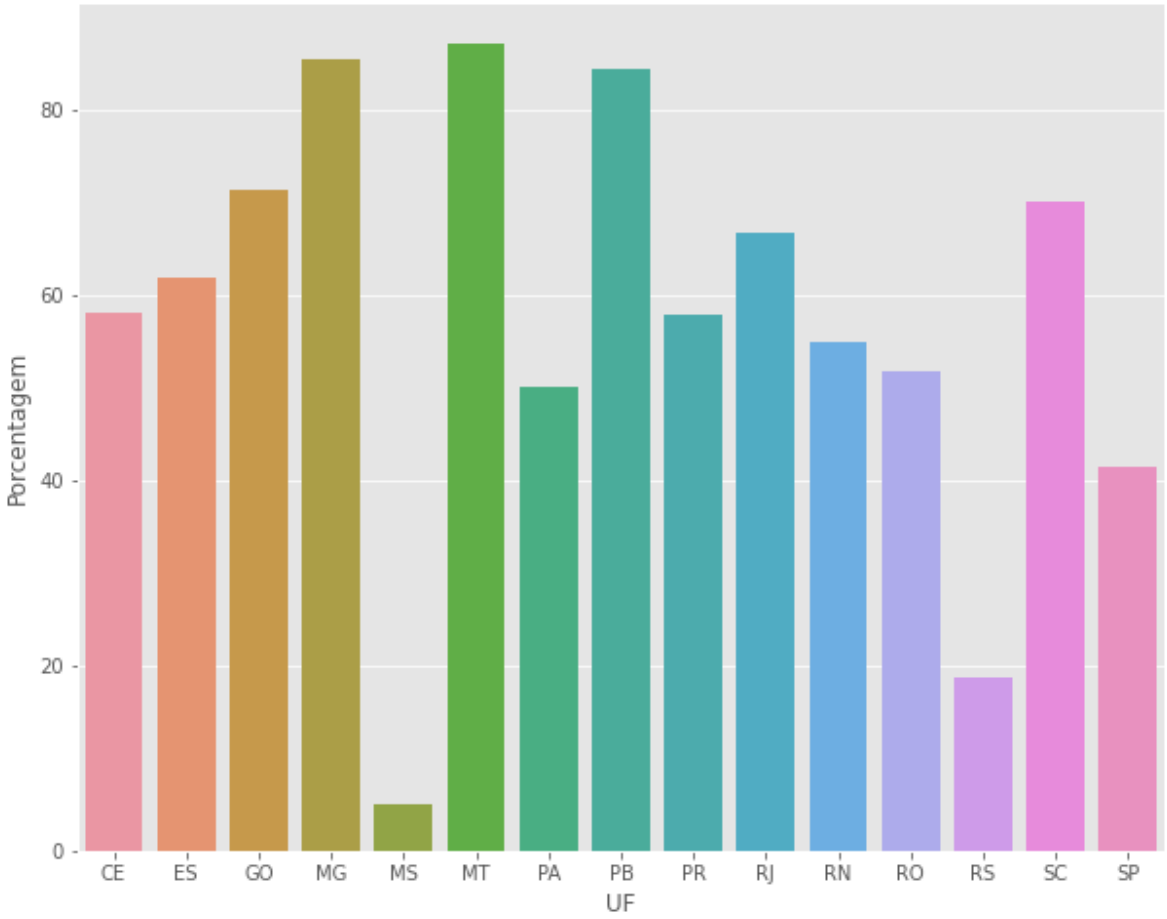

In [46]:

```
# Parece haver uma situação atípica com a UF Mato Grosso do Sul. Mais um gráfico para v
#x, y = 'UF','Atendida'
#df_uf = df_aed.groupby(x)[y].value_counts(normalize = True)
#df_uf = df_uf.mul(100)
# df_uf = df_uf.rename('Porcentagem').reset_index()
g = sns.catplot(x = x, y = 'Porcentagem', hue = y, kind = 'bar', data = df2, aspect = 2
for p in g.ax.patches:
    txt = str(p.get_height().round(2)) + '%'
    txt_x = p.get_x() + 0.03
    txt_y = p.get_height() + 1.5
    g.ax.text(txt_x, txt_y, txt, rotation = 90)
```

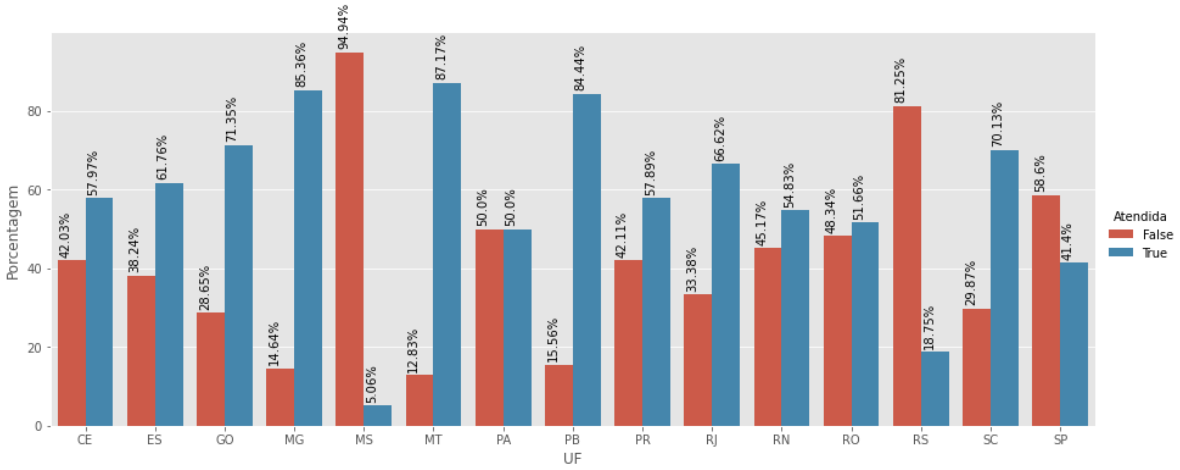

In [47]:

```
# Gráfico Bokeh para análise bivariada, monstrado valores absolutos (colunas) e relativ
g_uf = grafico_relacao_atributo_target(df_aed, "UF")
show(g_uf)
```

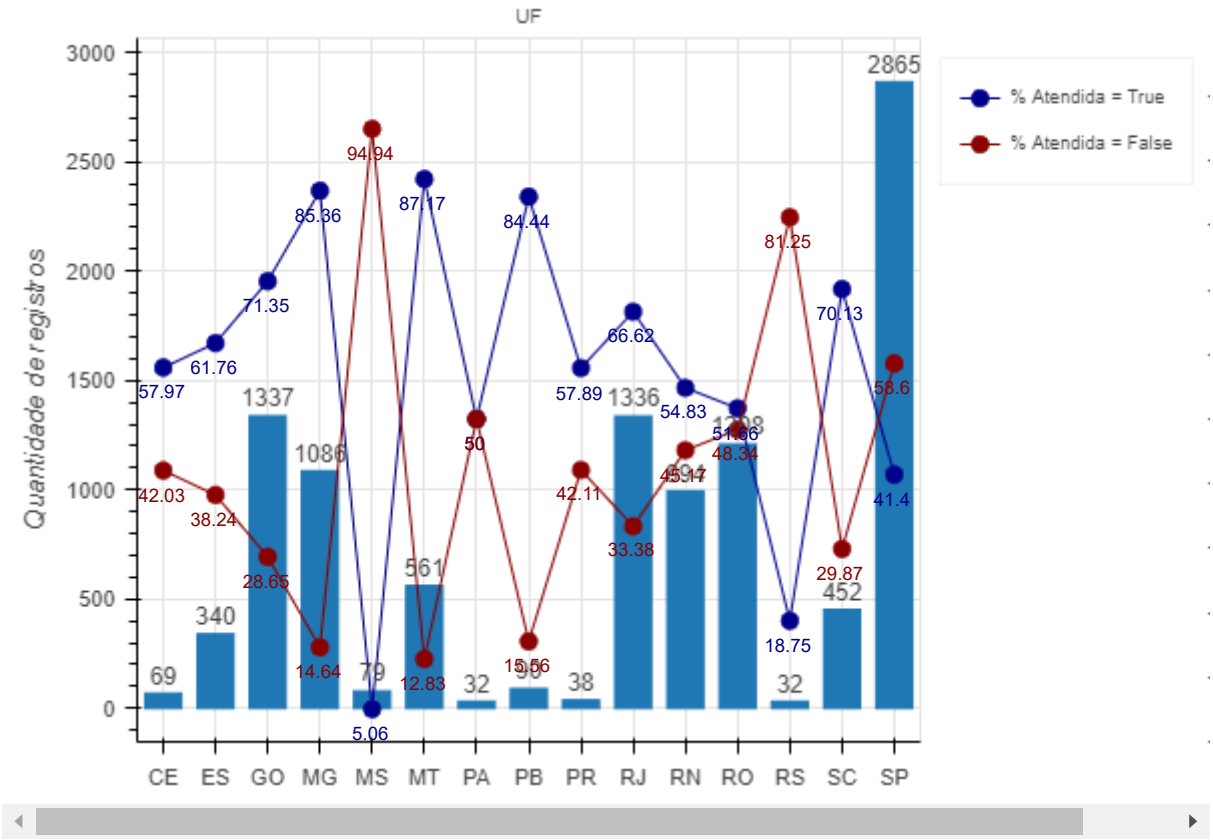

3) Coluna "CNAE" X target "Atendida"

In [48]:

```
# Da mesma forma que na análise univariada, a análise bivariada das categóricas com alt
# CEP - ficou prejudicada. Adicionalmente ao que conseguimos demonstrar na análise univ
# dez mais, por exemplo, ajudou: vários CNAE, CodAssunto e CEP com 100% de Atendida.
```

In [49]:

```
# Quantidades de vezes em que um CNAE corresponde a uma Atendida 'True'
df_aed.groupby('CNAE').agg({'Atendida': ['sum']})
```

Out[49]:

	Atendida
	sum
CNAE	
1031700.0	1
1092900.0	1
1093701.0	2
1099699.0	1
1311100.0	1
...	...
9529199.0	3
9601701.0	0
9602501.0	0
9602502.0	0
9603304.0	1

368 rows × 1 columns

In [50]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'CNAE','Atendida'
df_cnae = df_aed.groupby(x)[y].value_counts(normalize = True)
df_cnae = df_cnae.mul(100)
df3 = df_cnae.rename('Porcentagem').reset_index()
df3_filtrado =  df3[df3['Atendida']==True]
df3_filtrado
```

Out[50]:

	CNAE	Atendida	Porcentagem
0	1031700.0	True	100.000000
1	1092900.0	True	100.000000
2	1093701.0	True	66.666667
5	1099699.0	True	50.000000
7	1311100.0	True	50.000000
...	...	...	...
562	9521500.0	True	78.125000
564	9529103.0	True	100.000000
565	9529105.0	True	100.000000
566	9529199.0	True	75.000000
572	9603304.0	True	33.333333

295 rows × 3 columns

In [51]:

```
# Gráfico Prejudicado, assim, da mesma maneira que na análise univariada, selecionamos
plt.subplots(figsize=(5,5))
sns.barplot(x= 'CNAE', y= 'Porcentagem',data=df3_filtrado)
plt.show()
```

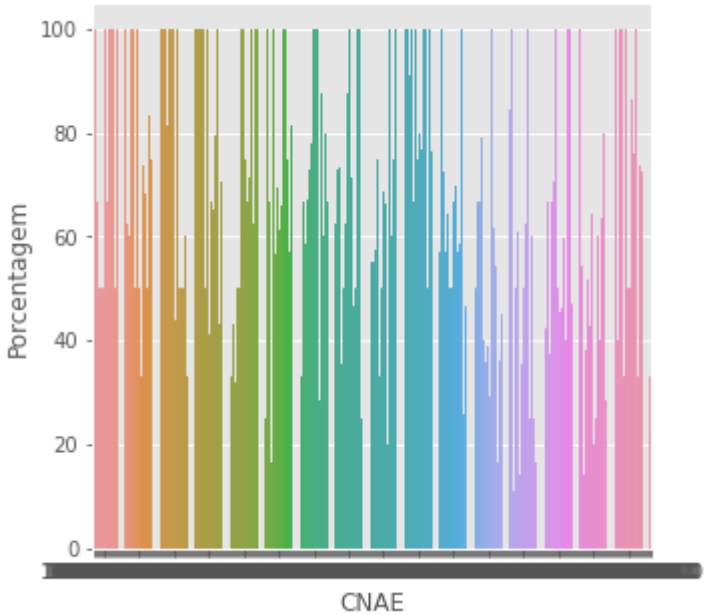

In [52]:

```
# Selecionando os maiores valores da variável de elevada cardinalidade X "Atendida"
```

In [53]:

```
pc_biv_cnae= df3_filtrado.sort_values(by='Porcentagem', ascending=False)
```

In [54]:

```
pc_biv_cnae
```

Out[54]:

	CNAE	Atendida	Porcentagem
0	1031700.0	True	100.000000
484	8299707.0	True	100.000000
160	4618403.0	True	100.000000
159	4618402.0	True	100.000000
157	4541205.0	True	100.000000
...	...	...	...
173	4643501.0	True	16.666667
432	6821802.0	True	14.285714
128	4321500.0	True	14.285714
498	8520100.0	True	14.285714
425	6810201.0	True	11.111111

295 rows × 3 columns

In [55]:

```
pc_biv_cnae_dez = pc_biv_cnae[:10]
```

In [56]:

```
pc_biv_cnae_dez
```

Out[56]:

	CNAE	Atendida	Porcentagem
0	1031700.0	True	100.0
484	8299707.0	True	100.0
160	4618403.0	True	100.0
159	4618402.0	True	100.0
157	4541205.0	True	100.0
156	4541204.0	True	100.0
320	5620102.0	True	100.0
152	4530704.0	True	100.0
323	5812300.0	True	100.0
145	4520007.0	True	100.0

In [57]:

```
# Mesmo segmentado para apenas os que tiveram 100% Atendidas, o gráfico continuaria sem
# com valor máximo
```

4) Coluna "CodAssunto" X target "Atendida"

In [58]:

```
# Da mesma forma que na análise univariada, a análise bivariada das categóricas com alt
# CEP - ficou prejudicada. Adicionalmente ao que conseguimos demonstrar na análise univ
# dez mais, por exemplo, ajudou: vários CNAE, CodAssunto e CEP com 100% de Atendida.
```

In [59]:

```
# Quantidades de vezes em que um CNAE corresponde a uma Atendida 'True'
df_aed.groupby('CodAssunto').agg({'Atendida': ['sum']})
```

Out[59]:

	Atendida
	sum
CodAssunto	
10.0	1
100.0	28
101.0	678
102.0	136
103.0	65
...	...
95.0	41
96.0	157
97.0	68
98.0	12
99.0	10

175 rows × 1 columns

In [60]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'CodAssunto','Atendida'
df_ca = df_aed.groupby(x)[y].value_counts(normalize = True)
df_ca = df_ca.mul(100)
df4 = df_ca.rename('Porcentagem').reset_index()
df4_filtrado =  df4[df4['Atendida']==True]
df4_filtrado
```

Out[60]:

	CodAssunto	Atendida	Porcentagem
0	10.0	True	100.000000
1	100.0	True	50.909091
3	101.0	True	75.501114
5	102.0	True	64.454976
7	103.0	True	75.581395
...	...	...	...
298	95.0	True	71.929825
300	96.0	True	65.966387
302	97.0	True	68.686869
304	98.0	True	70.588235
307	99.0	True	50.000000

156 rows × 3 columns

In [61]:

```
# Gráfico Prejudicado, assim, da mesma maneira que na análise univariada, selecionamos
plt.subplots(figsize=(5,5))
sns.barplot(x= 'CodAssunto', y= 'Porcentagem',data=df4_filtrado)
plt.show()

```

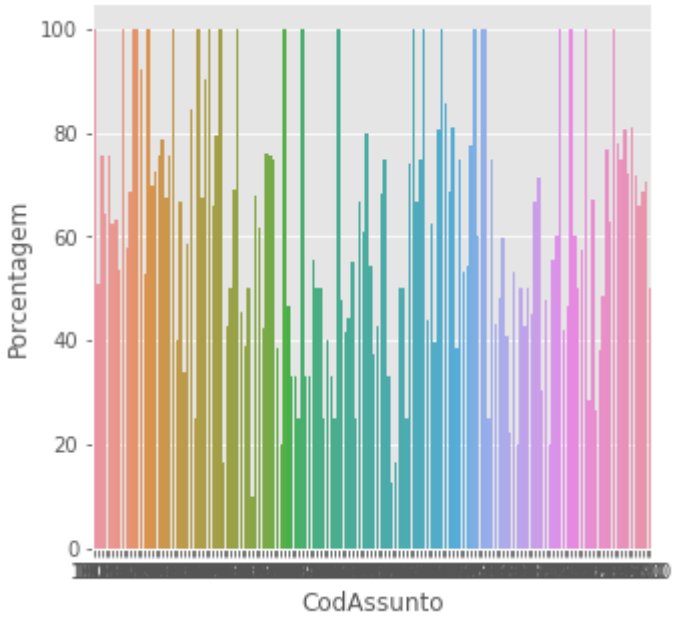

In [62]:

```
# Selecionando os maiores valores da variável de elevada cardinalidade X "Atendida"
```

In [63]:

```
pc_biv_ca= df4_filtrado.sort_values(by='Porcentagem', ascending=False)
pc_biv_ca_dez = pc_biv_ca[:10]
pc_biv_ca_dez
```

Out[63]:

	CodAssunto	Atendida	Porcentagem
0	10.0	True	100.0
42	128.0	True	100.0
61	14.0	True	100.0
67	143.0	True	100.0
76	15.0	True	100.0
287	9.0	True	100.0
102	202.0	True	100.0
270	8.0	True	100.0
111	21.0	True	100.0
263	75.0	True	100.0

In [64]:

```
# Mesmo segmentado para apenas os que tiveram 100% Atendidas, o gráfico continuaria sem
# com valor máximo
```

5) Coluna "SexoConsumidor" X target "Atendida"

In [65]:

```
# Quantidade em que a Atendida é "True"
df_aed.groupby('SexoConsumidor').agg({'Atendida': ['sum']})
```

Out[65]:

	Atendida
	sum
SexoConsumidor	
F	3302
M	3004

In [66]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'SexoConsumidor','Atendida'
df_sc = df_aed.groupby(x)[y].value_counts(normalize = True)
df_sc = df_sc.mul(100)
df5 = df_sc.rename('Porcentagem').reset_index()
df5_filtrado =  df5[df5['Atendida']==True]
df5_filtrado
```

Out[66]:

	SexoConsumidor	Atendida	Porcentagem
0	F	True	59.721469
2	M	True	60.200401

In [67]:

```
#Acrescentaremos números a este barplot as colunas pq ficaram muito parecidas.
plot = sns.barplot(data=df5_filtrado,x='SexoConsumidor',y='Porcentagem',palette=['r','b
for i in plot.patches:
    print(i)
for i in plot.patches:
     plot.annotate(i.get_height(),
                   (i.get_x() + i.get_width() / 2, i.get_height()),
                   ha='center',
                   va='baseline',
                   fontsize=12,
                   color='black',
                   xytext=(0, 1),
                   textcoords='offset points')
```

```
Rectangle(xy=(-0.4, 0), width=0.8, height=59.7215, angle=0)
Rectangle(xy=(0.6, 0), width=0.8, height=60.2004, angle=0)
```

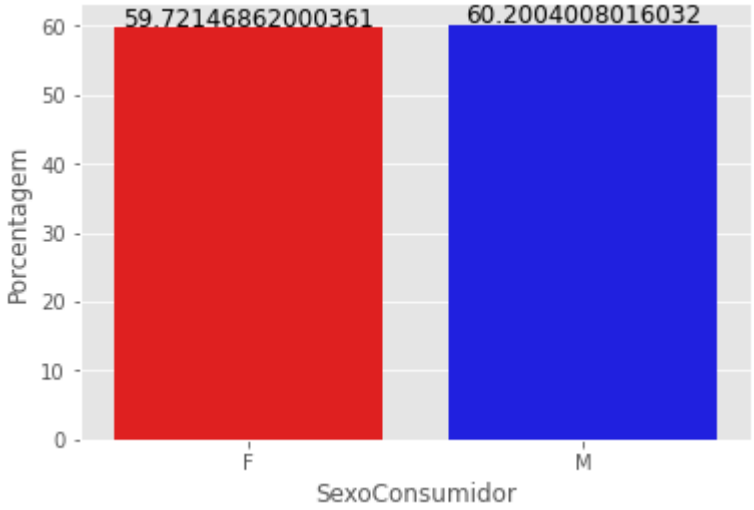

In [68]:

```
#Gráfico lado a lado para melhor visualização do problema acima
x, y = 'SexoConsumidor','Atendida'
df = df_aed.groupby(x)[y].value_counts(normalize = True)
df = df.mul(100)
df = df.rename('Porcentagem').reset_index()

g = sns.catplot(x = x, y = 'Porcentagem', hue = y, kind = 'bar', data = df5, aspect = 1
g.set_xticklabels(rotation = 60)
g.ax.set_ylim(0, 100)

for p in g.ax.patches:
    txt = str(p.get_height().round(2)) + '%'
    txt_x = p.get_x() + 0.03
    txt_y = p.get_height() + 1.5
    g.ax.text(txt_x, txt_y, txt, rotation = 90)

```

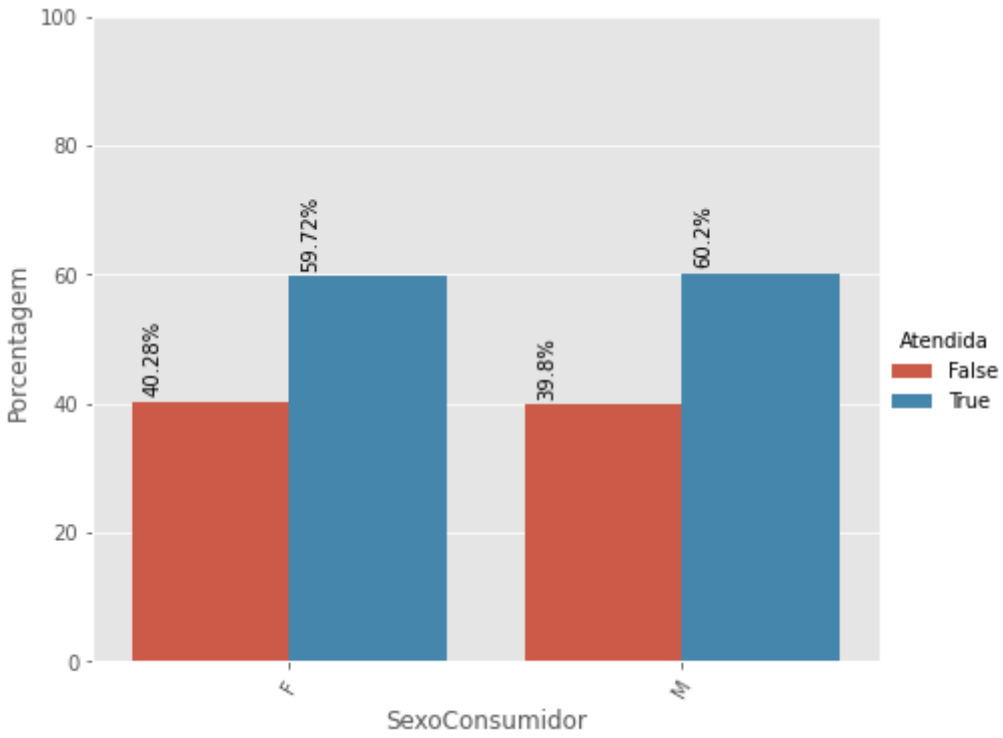

In [69]:

```
# Gráfico Bokeh para análise bivariada, monstrado valores absolutos (colunas) e relativ
g_sc  = grafico_relacao_atributo_target(df_aed, "SexoConsumidor")
show(g_sc)
```

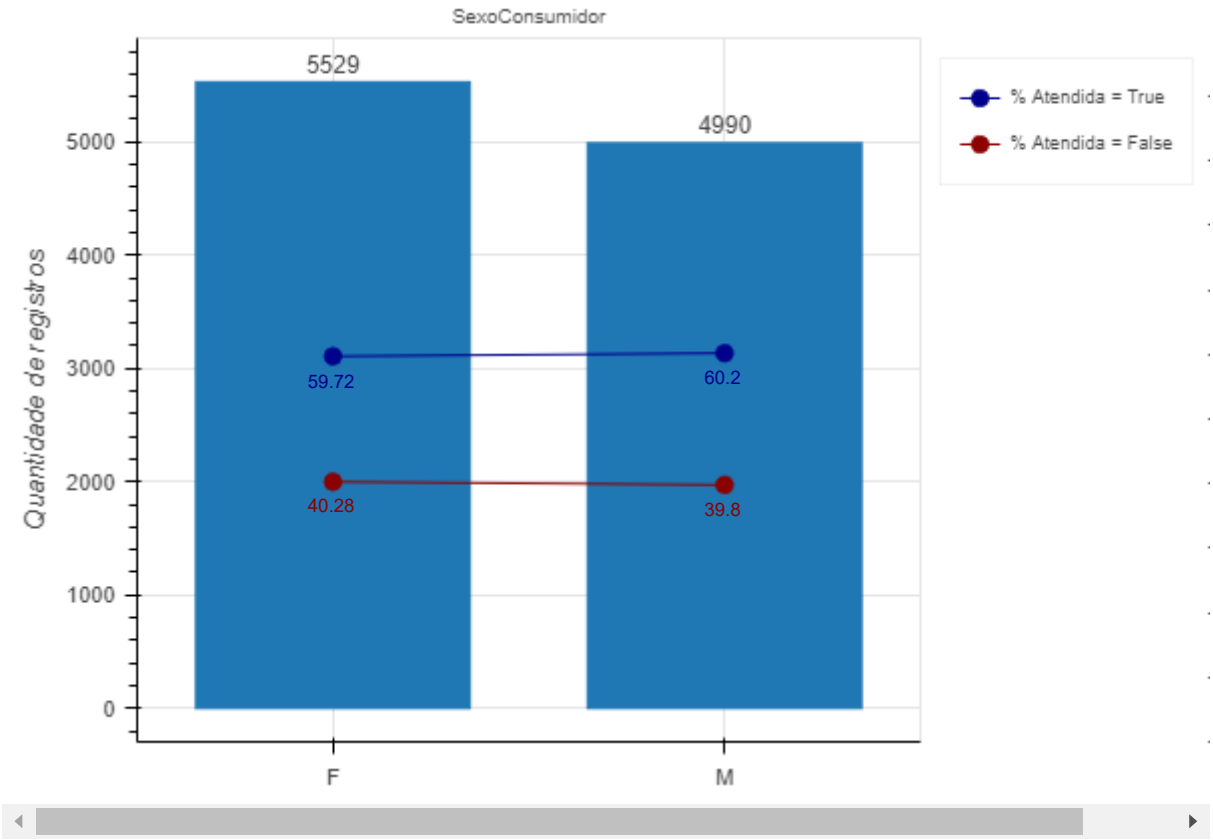

6) Coluna "FaixaEtaria" X target "Atendida"

In [70]:

```
# Quantidade em que a Atendida é "True"
df_aed.groupby('FaixaEtaria').agg({'Atendida': ['sum']})
```

Out[70]:

	Atendida
	sum
FaixaEtaria	
1	139
2	956
3	1465
4	1251
5	1061
6	1025
7	409

In [71]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'FaixaEtaria','Atendida'
df_fa = df_aed.groupby(x)[y].value_counts(normalize = True)
df_fa = df_fa.mul(100)
df6 = df_fa.rename('Porcentagem').reset_index()
df6_filtrado =  df6[df6['Atendida']==True]
df6_filtrado
```

Out[71]:

	FaixaEtaria	Atendida	Porcentagem
0	1	True	70.918367
2	2	True	59.712680
4	3	True	59.528647
6	4	True	59.429929
8	5	True	58.425110
10	6	True	63.388992
12	7	True	56.569848

In [72]:

```
# Gráfico do percentual de demandas 'Atendida' True e False por faixa etária
x, y = 'FaixaEtaria','Atendida'
df_fa = df_aed.groupby(x)[y].value_counts(normalize = True)
df_fa = df_fa.mul(100)
df_fa = df_fa.rename('Porcentagem').reset_index()
g = sns.catplot(x = x, y = 'Porcentagem', hue = y, kind = 'bar', data = df_fa, palette=
for p in g.ax.patches:
    txt = str(p.get_height().round(2)) + '%'
    txt_x = p.get_x() + 0.03
    txt_y = p.get_height() + 1.5
    g.ax.text(txt_x, txt_y, txt, rotation = 90)
```

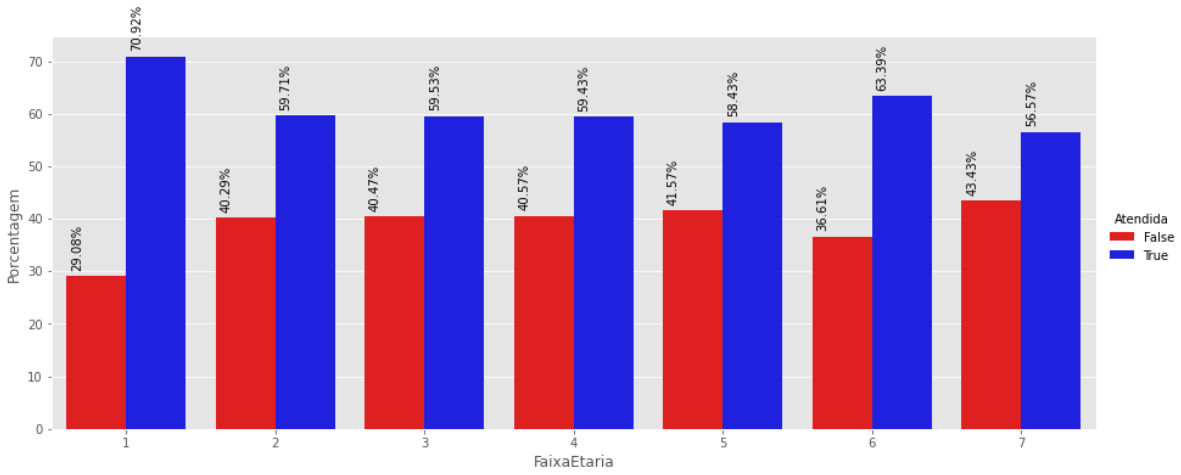

Uma constatação para o gráfico acima, é que, embora as demandas do público mais jovem tenham mais percentual de atendimento com sucesso, elas representam pouco no cômputo geral, pois:

```
Valores únicos (7,)
[5 4 3 6 7 2 1]
3    2461
4    2105
5    1816
6    1617
2    1601
7     723
1     196
Name: FaixaEtaria, dtype: int64
```

In [73]:

```
# Mais um gráfico mostrando como a quantidade dessa faixa etária dos mais novos é peque
f, ax = plt.subplots(figsize = (15, 8))
sns.histplot(
    df_aed[['FaixaEtaria', 'Atendida']],
    x = 'FaixaEtaria',
    hue = 'Atendida',
    multiple = 'stack',
    bins = 10,
    binrange = (0, 10),
    palette=['r','b']
)
ax.set_xlim(0, 10)
plt.show()
```

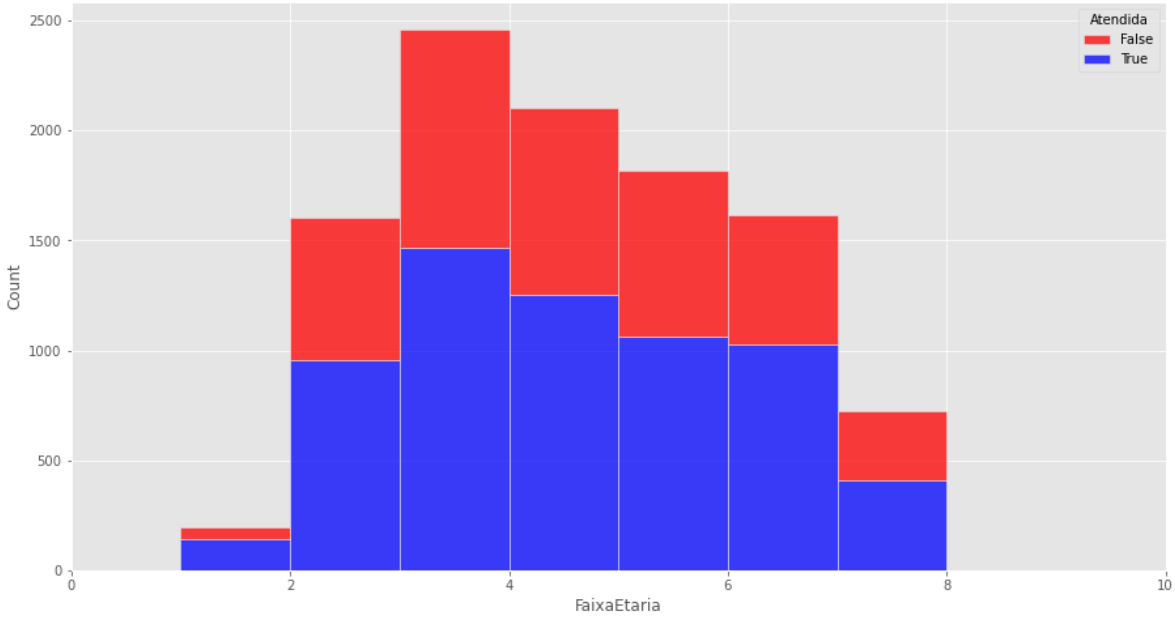

In [74]:

```
# Gráfico Bokeh para análise bivariada, monstrado valores absolutos (colunas) e relativ
g_fe  = grafico_relacao_atributo_target(df_aed, "FaixaEtaria")
show(g_fe)
```

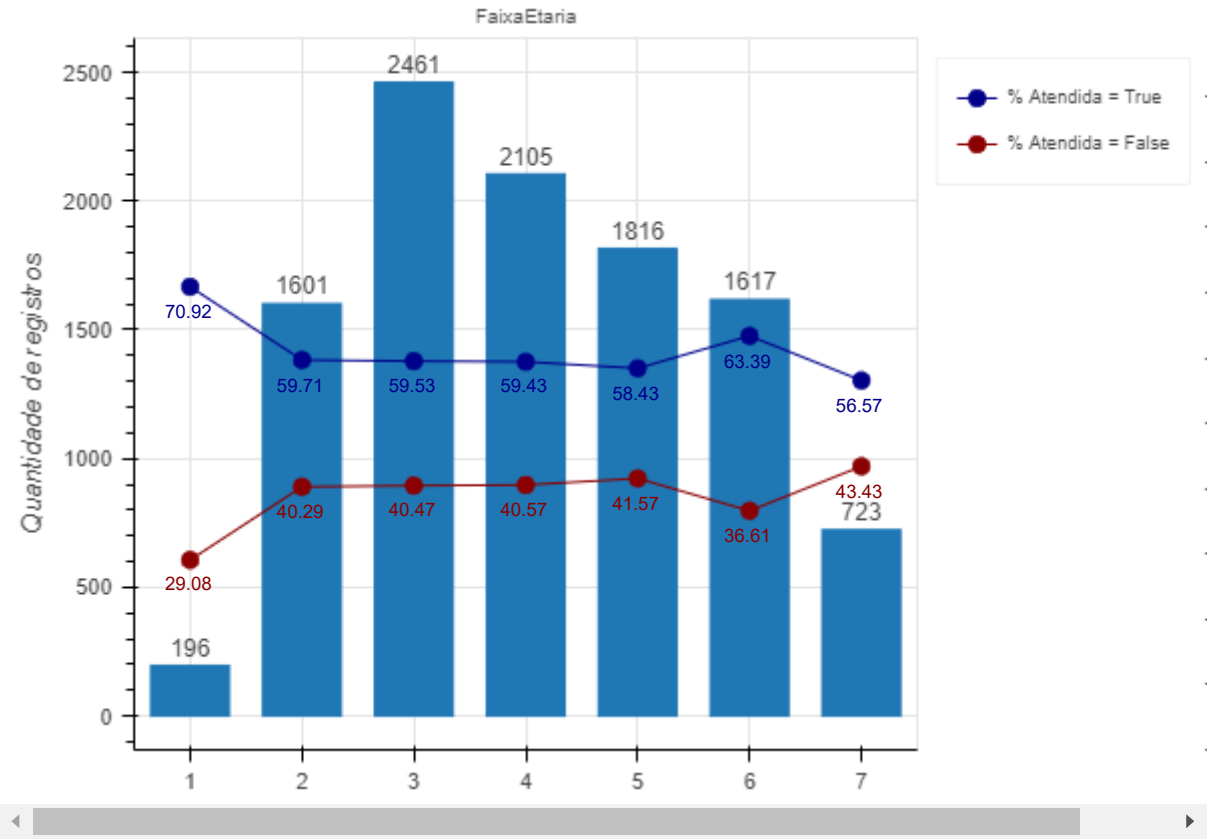

7) Coluna "CEP" X target "Atendida"

In [75]:

```
# Da mesma forma que na análise univariada, a análise bivariada das categóricas com alt
# CEP - ficou prejudicada. Adicionalmente ao que conseguimos demonstrar na análise univ
# dez mais, por exemplo, ajudou: vários CNAE, CodAssunto e CEP com 100% de Atendida.
```

In [76]:

```
# Quantidades em que a Atendida é 'True'
df_aed.groupby('CEP').agg({'Atendida': ['sum']})
```

Out[76]:

CEP	Atendida sum
1005010.0	0
1017000.0	0
1020000.0	0
1020010.0	0
1020904.0	0
...	...
9942098.0	0
9950300.0	0
9963370.0	0
9980460.0	0
9990244.0	1

6354 rows × 1 columns

Repetindo o que discorremos na análise univariada, a variável CEP é de uma cardinalidade que beira a inutilidade. Mantemos, apenas, porque pode ser fator que influencie decisivamente na variável target

In [77]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'CEP','Atendida'
df_cep = df_aed.groupby(x)[y].value_counts(normalize = True)
df_cep = df_cep.mul(100)
df7 = df_cep.rename('Porcentagem').reset_index()
df7_filtrado =  df7[df7['Atendida']==True]
df7_filtrado
```

Out[77]:

	CEP	Atendida	Porcentagem
6	1032010.0	True	100.0
10	1102000.0	True	100.0
12	11025020.0	True	100.0
19	11065050.0	True	100.0
21	11065651.0	True	100.0
...	...	...	...
6723	9861040.0	True	100.0
6727	9910650.0	True	100.0
6728	9920110.0	True	100.0
6730	9940460.0	True	100.0
6736	9990244.0	True	100.0

3825 rows × 3 columns

In [78]:

```
# Gráfico Prejudicado, assim, da mesma maneira que na análise univariada, selecionamos
plt.subplots(figsize=(5,5))
sns.barplot(x= 'CEP', y= 'Porcentagem',data=df7_filtrado)
plt.show()
```

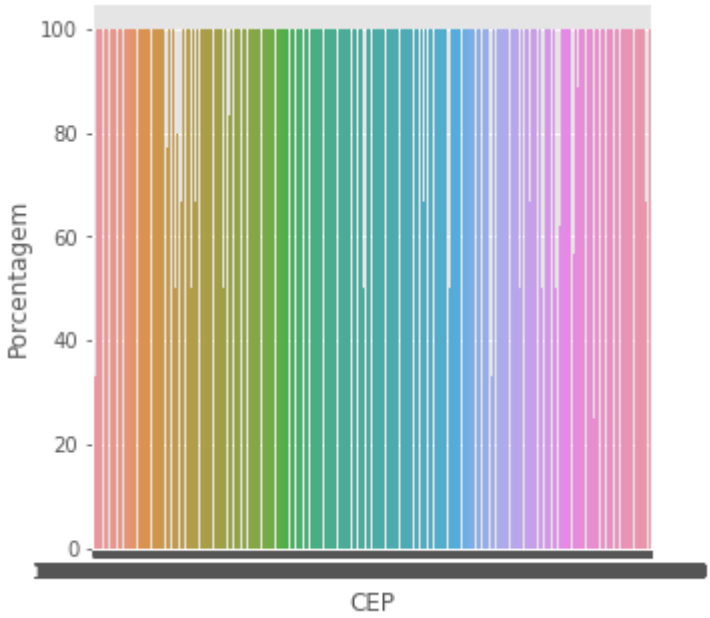

In [79]:

```
#Tentativa com o Bokeh de melhorar o gráfico
df7_filtrado.plot_bokeh(kind='bar', x='CEP', y='Porcentagem',category='Atendida')
```

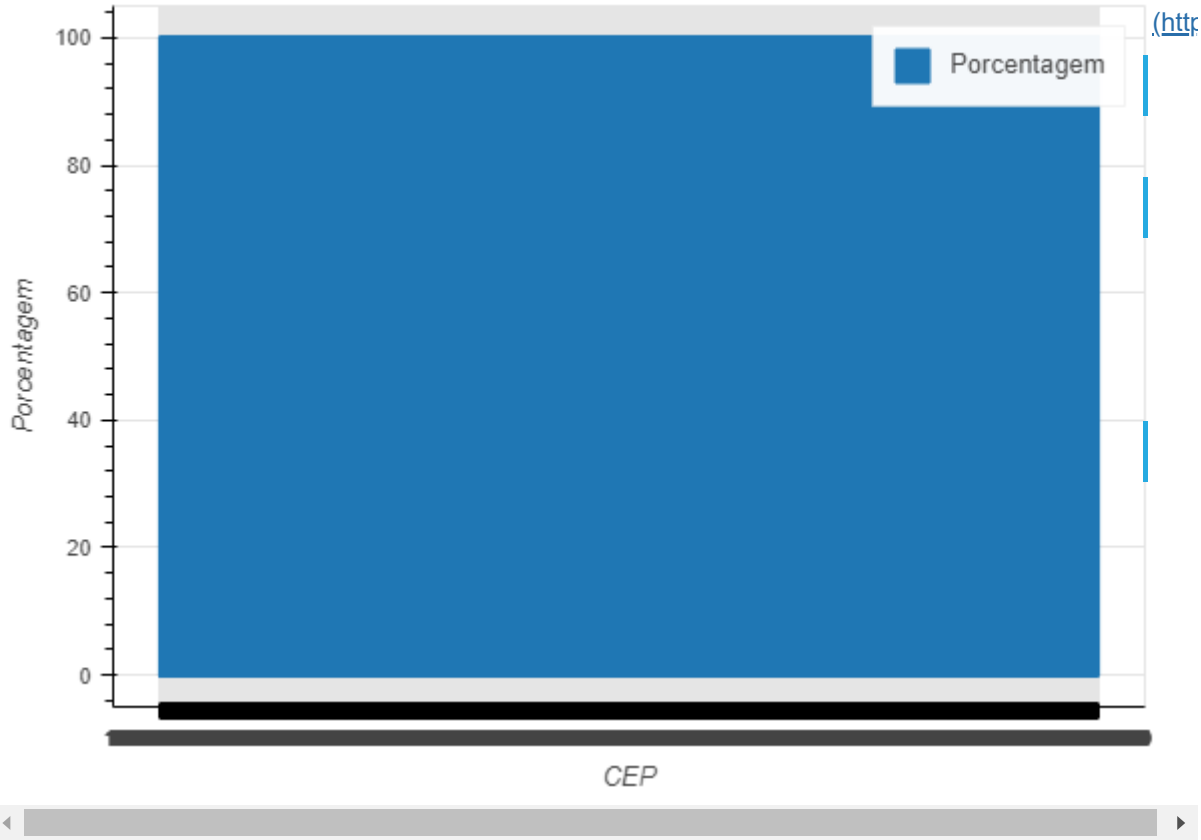

Out[79]:

Figure(id = '1887', …)

In [80]:

```
# Selecionando os maiores valores da variável de elevada cardinalidade X "Atendida"

pc_biv_cep= df7_filtrado.sort_values(by='Porcentagem', ascending=False)
pc_biv_cep_dez = pc_biv_cep[:10]
pc_biv_cep_dez
```

Out[80]:

	CEP	Atendida	Porcentagem
6	1032010.0	True	100.0
4413	63180970.0	True	100.0
4471	6775300.0	True	100.0
4473	6785070.0	True	100.0
4475	6787370.0	True	100.0
4476	6790100.0	True	100.0
4477	67961.0	True	100.0
4479	6810480.0	True	100.0
4480	68140000.0	True	100.0
4481	6815620.0	True	100.0

In [81]:

```
# Mesmo segmentado para apenas os que tiveram 100% Atendidas, o gráfico continuaria sem
# com valor máximo
```

8) Coluna "InscritoDAU" X target "Atendida"

In [82]:

```
#AtendidaXInscritoDAU
```

In [83]:

```
# Quantidade em que a Atendida é "True"

df_aed.groupby('Atendida').agg({'InscritoDAU': ['sum']})
```

Out[83]:

	InscritoDAU
	sum
Atendida	
False	2689
True	3676

In [84]:

```
#Porcentagem em que a Atendida é "True"
x, y = 'InscritoDAU','Atendida'
df_dau = df_aed.groupby(x)[y].value_counts(normalize = True)
df_dau = df_dau.mul(100)
df8 = df_dau.rename('Porcentagem').reset_index()
df8_filtrado =  df8[df8['Atendida']==True]
df8_filtrado
```

Out[84]:

	InscritoDAU	Atendida	Porcentagem
0	False	True	63.312470
2	True	True	57.753339

In [85]:

```
#Barplot mostrando que as demandas pertencentes a empresas que tem DAU (InscritoDAU=Tru
# as que tem porcentagem de demandas Atendidas menor
plt.subplots(figsize=(10,8))
sns.barplot(x= df8_filtrado['InscritoDAU'], y= df8_filtrado['Porcentagem'])
plt.show()
```

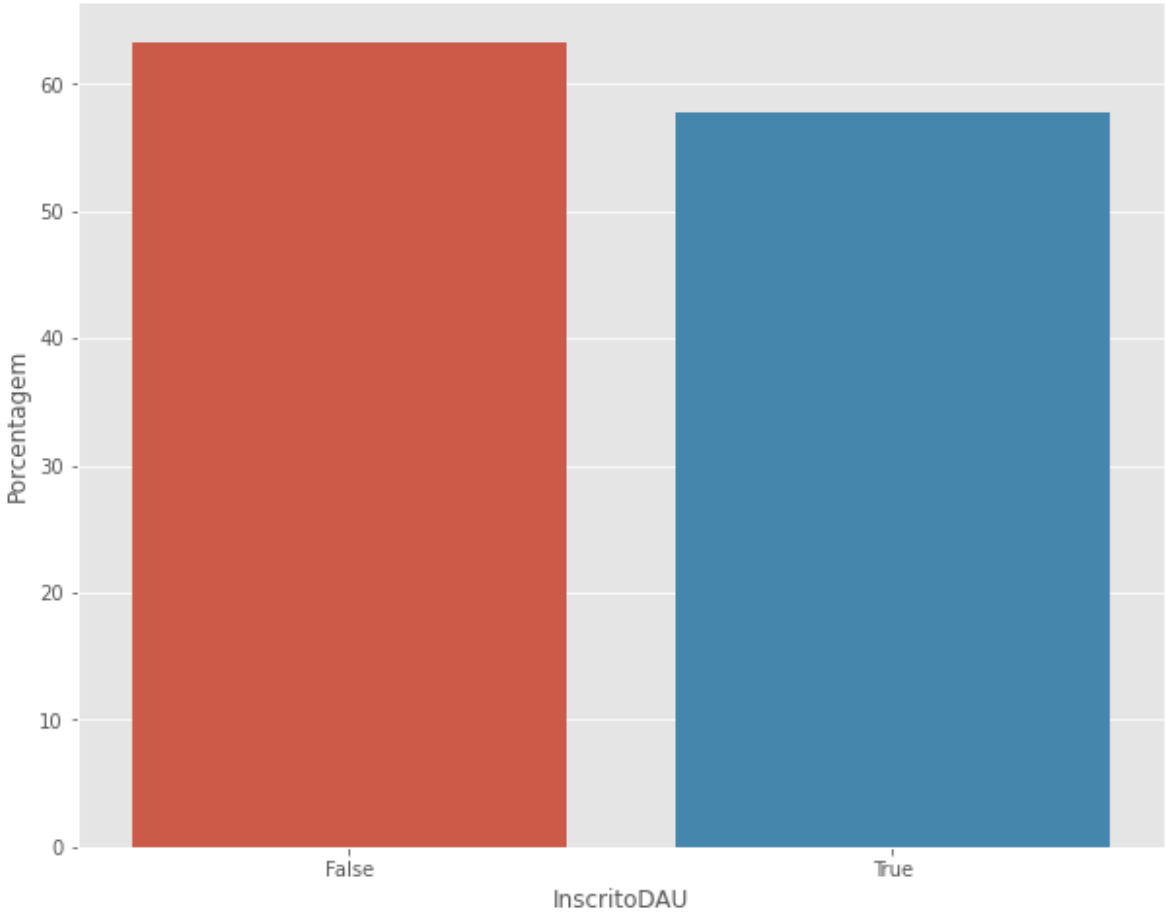

In [86]:

```
# Gráfico Bokeh para análise bivariada, monstrado valores absolutos (colunas) e relativ
g_dau  = grafico_relacao_atributo_target(df_aed, "InscritoDAU")
show(g_dau)
```

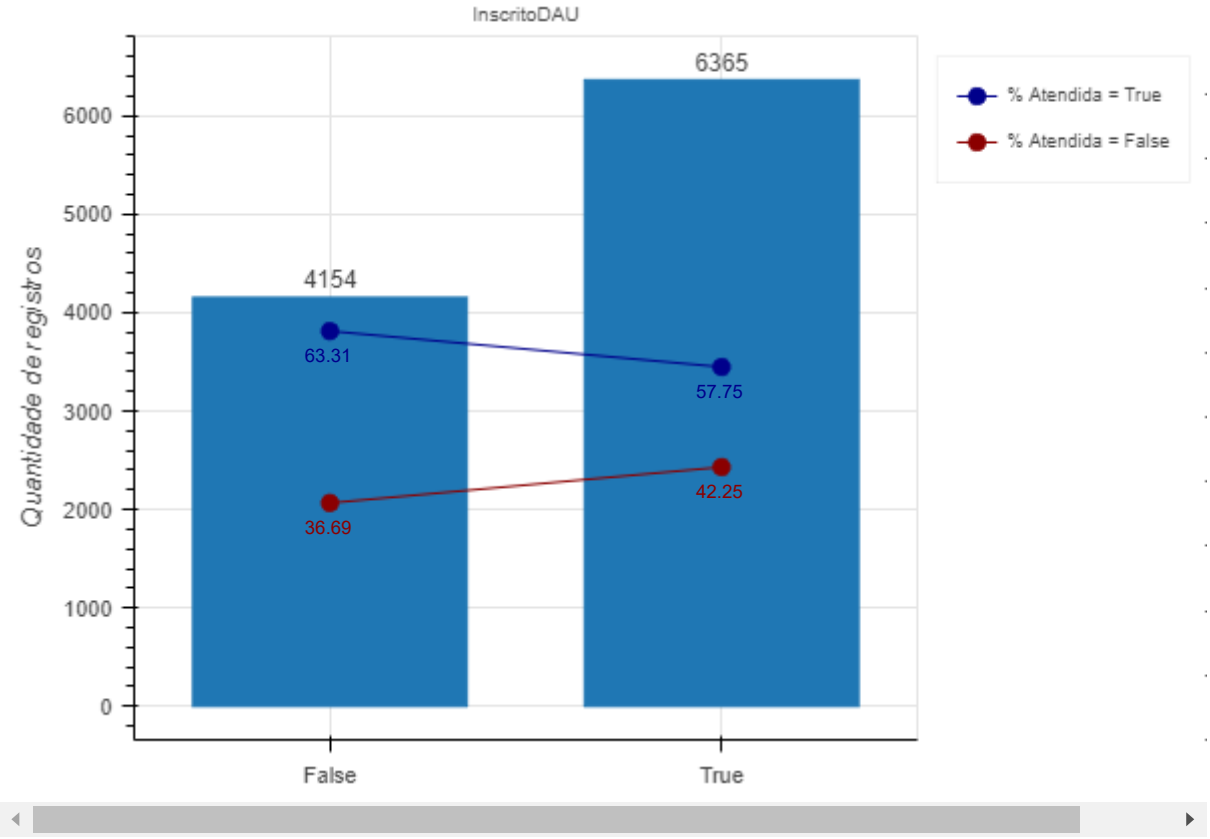

Sweetviz

Não obstante o trabalho manual discorrido até aqui, existe a biblioteca open-source Sweetviz que automatiza o que foi demonstrado acima. Temos variáveis categóricas. O Sweetviz demonstra o coeficiente de incerteza entre as variáveis categóricas.

In [87]:

```
import sweetviz as sv
```

In [88]:

```
report = sv.analyze(df_aed, 'Atendida')

```

A Jupyter widget could not be displayed because the widget state could not be found. This could happen if the kernel storing the widget is no longer available, or if the widget state was not saved in the notebook. You may be able to create the widget by running the appropriate cells.

In [89]:

```
# Clicando no botão "Associations" é possível verificar as associações.
# A primeira coluna da tabela que aparece qnd se clica no botão "Associations"  é da va
report.show_notebook(layout = 'vertical')
```

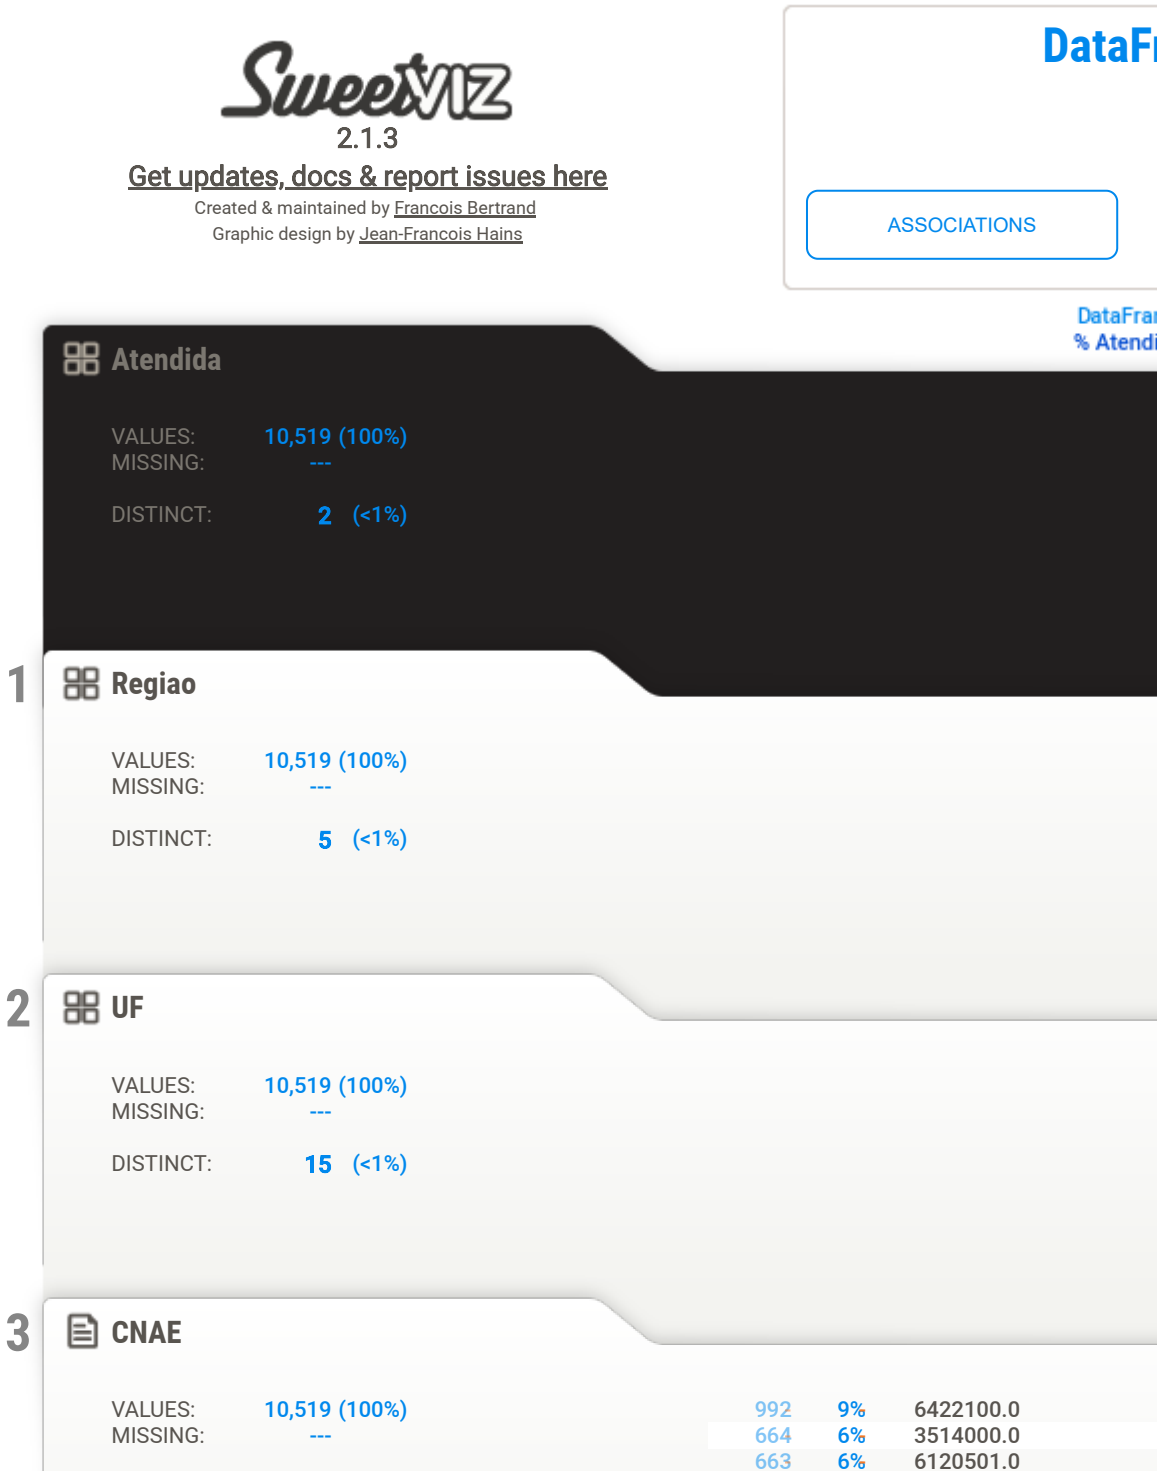

Apêndice de AED

Pairplot

In [90]:

```
1 sns.pairplot(df_aed)
```

```
<__array_function__ internals>:5: RuntimeWarning: Converting input from bool
to <class 'numpy.uint8'> for compatibility.
<__array_function__ internals>:5: RuntimeWarning: Converting input from bool
to <class 'numpy.uint8'> for compatibility.
<__array_function__ internals>:5: RuntimeWarning: Converting input from bool
to <class 'numpy.uint8'> for compatibility.
<__array_function__ internals>:5: RuntimeWarning: Converting input from bool
to <class 'numpy.uint8'> for compatibility.
```

Out[90]:

```
<seaborn.axisgrid.PairGrid at 0x26418aad670>
```